24. Επιστημη Δεδομενων και Pandas

24.1.0 Τι είναι η Επιστήμη των Δεδομένων και η βιβλιοθήκη Pandas

Η επιστήμη των δεδομένων είναι ένας κλάδος της Επιστήμης των Υπολογιστών στον οποίο μελετάμε τη χρήση, αποθήκευση και ανάλυση των δεδομένων ώστε να μπορούμε να εξάγουμε χρήσιμες πληροφορίες απ' αυτά.

Η βιβλιοθήκη Pandas είναι φτιαγμένη ειδικά γι' αυτό το λόγο. Έτσι, διαθέτει κατάλληλες λειτουργίες για τον χειρισμό, την ανάλυση και την εξερεύνηση δεδομένων. Το όνομα της βιβλιοθήκης είναι ένας συγκερασμός των λέξεων "Panel Data" ή "Python Data Analysis". Η βιβλιοθήκη δημιουργήθηκε από τον Wes McKinney το 2008. Ο Wes McKinney είναι προγραμματιστής, επιχειρηματίας και συγγραφέας και μπορούμε να βρούμε την 3η έκδοση του βιβλίου του "Python for Data Analysis", εδώ

Τι μπορούμε να κάνουμε με την Pandas

Η Pandas είναι μια βιβλιοθήκη, η οποία θα μπορούσαμε να πούμε πως είναι ένας πρόδρομος της τεχνητής νοημοσύνης, καθότι μπορούμε χρησιμοποιώντας τη να υποβάλλουμε ερωτήματα σχεδόν σε φυσική γλώσσα (αγγλικά) όπως:

- Υπάρχει συσχέτιση μεταξύ δύο ή περισσότερων στηλών;
- Ποια είναι η μέση τιμή;

- Μέγιστη τιμή;
- Ελάχιστη τιμή;

Επίσης, μπορούμε να κάνουμε καθαρισμό των δεδομένων, όπως διαγραφή σειρών που δεν μας ενδιαφέρουν ή περιέχουν άσχετες ή και λανθασμένες τιμές, όπως κενές τιμές ή τιμές NULL. Αυτό το χαρακτηριστικό της βιβλιοθήκης ονομάζεται καθαρισμός.

Η βιβλιοθήκη Pandas είναι open source και το αποθετήριό της βρίσκεται στο github, εδώ.

24.1.1 Εγκατάσταση και εισαγωγή

Η εγκατάσταση γίνεται όπως και με κάθε βιβλιοθήκη της Python, φυσικά με προϋποθέσεις την ύπαρξη της Python και του pip.

```
pip install pandas
```

Import Pandas

Με την εντολή import εισάγουμε και χρησιμοποιούμε τη βιβλιοθήκη όπως παρακάτω:

```
import pandas as pd
mydataset = {
  'cars': ["BMW", "Volvo", "Ford"],
  'passings': [3, 7, 2]
}

myvar = pd.DataFrame(mydataset)

print(myvar)
```

Η έξοδος είναι:

```
>>>
=== RESTART: C:\Users\NK\AppData\Local\Programs\Python\Python311\pandas_ex.py ==
    cars  passings
0    BMW         3
1  Volvo         7
2   Ford         2
>>>
```

Όπως και άλλες φορές, με τις βιβλιοθήκες μπορούμε να χρησιμοποιούμε aliases (ψευδώνυμα). Επίσης, μπορούμε όποτε θέλουμε να ελέγχουμε και την έκδοση της Pandas ή οποιασδήποτε βιβλιοθήκης, με την εντολή:

```
import pandas as pd
print(pd.__version__)
```

και η έξοδος στο IDLE είναι:

```
>>>
=== RESTART: C:\Users\NK\AppData\Local\Programs\Python\Python311\pandas_ex.py ==
2.1.0
>>>
```

24.1.2 Τι είναι οι σειρές – Series

Οι Pandas Series είναι όπως οι στήλες σε έναν πίνακα. Είναι ένας μονοδιάστατος πίνακας ο οποίος μπορεί να αποθηκεύσει δεδομένα οποιουδήποτε τύπου.

Δημιουργία Panda Series από μια λίστα:

```
import pandas as pd

a = [1, 7, 2]

myvar = pd.Series(a)

print(myvar)
```

Η έξοδος τώρα είναι:

```
>>>
= RESTART: C:\Users\NK\AppData\Local\Programs\Python\Python311\pandas_ex.py
0    1
1    7
2    2
dtype: int64
>>>
```

Αν αυτή η εκτύπωση μας φαίνεται παράξενη, είναι διότι δεν έχουμε ακόμα αναφέρει τις ετικέτες

24.1.3 Τι είναι οι ετικέτες – Labels

Πρόκειται για την αρίθμηση των τιμών. Αν δεν έχει αναφερθεί κάτι άλλο, τότε οι τιμές «ετικετάρονται» με τον index number τους, όπως στην παραπάνω εκτύπωση. Η αρίθμηση ξεκινάει από το «0» και μπορούμε να χρησιμοποιούμε τις ετικέτες για να έχουμε πρόσβαση στις τιμές τους, όπως παρακάτω.

Επιστροφή της 1ης τιμής (με index (0)):

```
import pandas as pd

a = [1, 7, 2]

myvar = pd.Series(a)

print(myvar[0])
```

Η έξοδος είναι: “1”

Δημιουργία ετικετών

Με την παράμετρο index, μπορούμε να δημιουργούμε τις δικές μας ετικέτες:

import pandas as pd

```
a = [2, 9, 3]

myvar = pd.Series(a, index = ["a", "b", "c"])

print(myvar)
```

Η έξοδος είναι:

```
>>>
=== RESTART: C:\Users\NK\AppData\Local\Programs\Python\Python311\pandas_ex.py ==
a     2
βb    9
c     3
dtype: int64
>>>
```

Όπως και παραπάνω, όταν έχουμε δημιουργήσει ετικέτες, μπορούμε να προσπελάσουμε μια τιμή με την ετικέτα της:

```
Print(myvar[“b”])
```

Η έξοδος είναι: «9».

Οι παραπάνω δηλώσεις, μας θυμίζουν λεξικά. Πράγματι, μπορούμε να δημιουργήσουμε Series από λεξικά

24.1.4 Αντικείμενα τύπου Κλειδί/Τιμή σαν Series

```
import pandas as pd

lessons =
{"day1": algebra, "day2": Language, "day3": Geography
}

myvar = pd.Series(calories)

print(myvar)
```

Έξοδος:

```
>>>
= RESTART: C:\Users\NK\AppData\Local\Programs\Python\Python311\pandas_ex.py
day1    420
day2    380
day3    390
dtype: int64
>>>
```

Ή μπορούμε να επιλέξουμε τα δεδομένα που χρειαζόμαστε, χρησιμοποιώντας τα index numbers:

```
import pandas as pd

lessons = {"day1": 420, "day2": 380, "day3": 390}

myvar = pd.Series(lessons, index = ["day1", "day2"])

print(myvar)
```

```
>>>
=== RESTART: C:\Users\NK\AppData\Local\Programs\Python\Python311\pandas_ex.py ==
day1    420
day2    380
dtype: int64
>>>
```

Τι είναι τα DataFrames

Τα data sets όσον αφορά τη βιβλιοθήκη Pandas, είναι συνήθως πολυδιάστατοι πίνακες που ονομάζονται DataFrames.

Αν Series είναι μια στήλη, τότε DataFrame είναι όλος ο πίνακας.

24.1.5 Δημιουργία DataFrame με δύο Series

```
import pandas as pd

data = {
  "calories": [420, 380, 390],
  "duration": [50, 40, 45]
}

myvar = pd.DataFrame(data)
```

```
print(myvar)
```

έτσι έχουμε:

```
>>>
=== RESTART: C:\Users\NK\AppData\Local\Programs\Python\Python311\pandas_ex.py ==
day1    420
day2    380
dtype: int64
>>>
```

Έτσι μπορούμε να πούμε ότι DataFrame είναι μια δομή δισδιάστατη, όπως ένας δισδιάστατος πίνακας, με γραμμές και στήλες.

```
Ας δούμε ένα DataFrame:
data = {
  "calories": [420, 380, 390],
  "duration": [50, 40, 45]
}

#load data into a DataFrame object:
df = pd.DataFrame(data)

print(df)
```

```
>>>
=== RESTART: C:\Users\NK\AppData\Local\Programs\Python\Python311\pandas_ex.py ==
   calories  duration
0       420        50
1       380        40
2       390        45
>>>
```

24.1.6 Ανεύρεση γραμμής σε ένα DataFrame

Η Pandas, χρησιμοποιεί το χαρακτηριστικό «loc» για να επιστρέψει μία ή περισσότερες γραμμές.

Παράδειγμα αναφοράς στην πρώτη γραμμή του DataFrame με το index (0):

import pandas as pd

```
data = {
  "calories": [420, 380, 390],
  "duration": [50, 40, 45]
}

#load data into a DataFrame object:
df = pd.DataFrame(data)

print(df.loc[0])
```

Έξοδος;

```
>>>
=== RESTART: C:\Users\NK\AppData\Local\Programs\Python\Python311\pandas_ex.py ==
calories    420
duration     50
Name: 0, dtype: int64
>>>
```

Επιστροφή 2 γραμμών, χρησιμοποιώντας λίστα indexes:

```
print(df.loc[[0, 1]])
```

```
>>>
=== RESTART: C:\Users\NK\AppData\Local\Programs\Python\Python311\pandas_ex.py ==
   calories  duration
0       420        50
1       380        40
>>>
```

24.1.7 Ονομαζόμενα Indexes

Με τα indexes, όπως κάναμε και παραπάνω, μπορούμε να ονομάζουμε τις αριθμήσεις μας:

```
import pandas as pd

data = {
  "calories": [420, 380, 390],
  "duration": [50, 40, 45]
```

```
}

df = pd.DataFrame(data, index =
["day1", "day2", "day3"])

print(df)
```

Έξοδος:

```
>>>
=== RESTART: C:\Users\NK\AppData\Local\Programs\Python\Python311\pandas_ex.py ==
      calories  duration
day1       420        50
day2       380        40
day3       390        45
>>>
```

Έτσι, μπορούμε να επιστρέψουμε οποιοδήποτε index, με μια απλή αναφορά στο όνομά του.

Ανεύρεση ονομαζόμενου index

```
print(df.loc["day2"])
```

```
>>>
=== RESTART: C:\Users\NK\AppData\Local\Programs\Python\Python311\pandas_ex.py ==
calories    380
duration     40
Name: day2, dtype: int64
>>>
```

24.1.8 Φόρτωση αρχείων σε DataFrame

Αν τα datasets βρίσκονται σε ένα αρχείο, η βιβλιοθήκη Pandas, μπορεί να τα φορτώσει σε ένα DataFrame. Τα δεδομένα πρέπει να βρίσκονται σε αρχείο csv.

Παράδειγμα:

```
import pandas as pd

df = pd.read_csv('C:\\Users\\NK\Desktop\\data.csv')
```

```
print(df)
```

Έξοδος:

```
>>>
=== RESTART: C:\Users\NK\AppData\Local\Programs\Python\Python311\pandas_ex.py ==
     Duration  Pulse  Maxpulse  Calories
0          60    110       130     409.1
1          60    117       145     479.0
2          60    103       135     340.0
3          45    109       175     282.4
4          45    117       148     406.0
..        ...    ...       ...       ...
164        60    105       140     290.8
165        60    110       145     300.4
166        60    115       145     310.2
167        75    120       150     320.4
168        75    125       150     330.4

[169 rows x 4 columns]
>>>
```

24.1.9 Άνοιγμα αρχείων

Τα αρχεία csv είναι απλά αρχεία κειμένου και χρησιμοποιούνται ευρέως για την αποθήκευση μεγάλων data sets.

Μπορούν, όπως ήδη είδαμε να διαβαστούν από το Pandas. Μπορούμε να κατεβάσουμε ένα αρχείο csv, το data.csv, από δω

Τώρα, ας το φορτώσουμε σε ένα DataFrame:

```
import pandas as pd

df = pd.read_csv('C:\\Users\\NK\\Desktop\\data.csv')

print(df.to_string())
```

Από το IDLE θα πάρουμε μια έξοδο με συμπιεσμένο περιεχόμενο, όπως γίνεται και σε κάθε περιεχόμενο, όταν είναι αρκετά μεγάλο για εκτύπωση.

Εδώ, χρησιμοποιούμε την to_string() για να πάρουμε την εκτύπωση όλου του DataFrame.

Αν το DataFrame είναι πολύ μεγάλο, με αρκετές γραμμές, το Pandas θα φορτώσει μόνο τις 5 πρώτες και τις 5 τελευταίες γραμμές.

Ας το δούμε, χωρίς τη χρήση της to_string()

```
import pandas as pd

df = pd.read_csv('data.csv')

print(df)
```

Παίρνουμε:

```
>>>
=== RESTART: C:\Users\NK\AppData\Local\Programs\Python\Python311\pandas_ex.py ==
     Duration  Pulse  Maxpulse  Calories
0          60    110       130     409.1
1          60    117       145     479.0
2          60    103       135     340.0
3          45    109       175     282.4
4          45    117       148     406.0
..        ...    ...       ...       ...
164        60    105       140     290.8
165        60    110       145     300.4
166        60    115       145     310.2
167        75    120       150     320.4
168        75    125       150     330.4

[169 rows x 4 columns]
>>>
```

Ο παραπάνω αριθμός των 5 και 5 επιστρεφόμενων γραμμών, είναι καθορισμένος στις επιλογές ρυθμίσεων του Pandas. Μπορούμε να τον ελέγξουμε:

```
import pandas as pd

print(pd.options.display.max_rows)
```

Στα περισσότερα συστήματα, από προεπιλογή, θα πάρουμε σαν έξοδο τον αριθμό «60».

Αυτό σημαίνει ότι αν το Dataframe περιέχει περισσότερες από 60 γραμμές, η δήλωση print(df) θα επιστρέψει μόνο τις επικεφαλίδες των στηλών και τις πρώτες και τελευταίες 5 στήλες.

Μπορούμε να αλλάξουμε τον μέγιστο αριθμό των γραμμών με την ίδια δήλωση, δίνοντας τον δικό μας:

```
import pandas as pd

pd.options.display.max_rows = 9999

df = pd.read_csv('data.csv')

print(df)
```

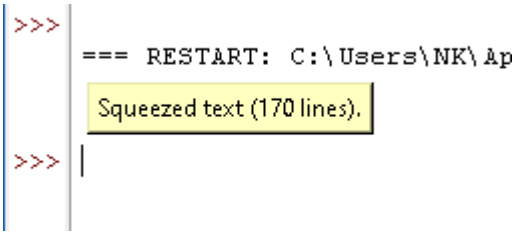

24.1.10 Ανάγνωση αρχείων JSON

Τα μεγάλα σύνολα δεδομένων (big data) συχνά αποθηκεύονται ή εξάγονται ως αρχεία JSON.

Τα JSON είναι αρχεία απλού κειμένου, αλλά έχουν τη μορφή ενός αντικειμένου και είναι πολύ γνωστά στον κόσμο του προγραμματισμού, συμπεριλαμβανομένου του Pandas.

Στα παραδείγματά μας θα χρησιμοποιήσουμε ένα αρχείο JSON που ονομάζεται 'data.json' και μπορούμε να το κατεβάσουμε από δω.

```
import pandas as pd

df = pd.read_json('data.json')

print(df.to_string())
```

Λεξικό ως JSON

Τα αντικείμενα JSON έχουν την ίδια μορφή με τα λεξικά Python.

Εάν ο κώδικας JSON δεν βρίσκεται σε αρχείο, αλλά σε λεξικό της Python, μπορούμε να τον φορτώσουμε απευθείας σε ένα DataFrame:

Παράδειγμα:

```
import pandas as pd

data = {
  "Duration":{
    "0":60,
    "1":60,
    "2":60,
    "3":45,
    "4":45,
    "5":60   },
  "Pulse":{
    "0":110,
    "1":117,
    "2":103,
    "3":109,
    "4":117,
    "5":102   },
  "Maxpulse":{
    "0":130,
    "1":145,
    "2":135,
    "3":175,
    "4":148,
    "5":127   },
  "Calories":{
    "0":409,
    "1":479,
    "2":340,
    "3":282,
    "4":406,
    "5":300   }
}

df = pd.DataFrame(data)

print(df)
```

Και σαν έξοδο παίρνουμε:

```
>>>
=== RESTART: C:\Users\NK\AppData\Local\Progra
   Duration  Pulse  Maxpulse  Calories
0        60    110       130       409
1        60    117       145       479
2        60    103       135       340
3        45    109       175       282
4        45    117       148       406
5        60    102       127       300
>>>
```

24.1.11 Ανάλυση των DataFrames

Προβολή των Δεδομένων

Μία από τις πιο χρησιμοποιούμενες μεθόδους για γρήγορη επισκόπηση του DataFrame είναι η μέθοδος head().

Η μέθοδος head() επιστρέφει τις κεφαλίδες και έναν καθορισμένο αριθμό σειρών, ξεκινώντας από την κορυφή.

Μπορούμε για παράδειγμα να έχουμε για γρήγορη επισκόπηση ενός DataFrame εκτυπώνοντας τις πρώτες 10 σειρές.

```
import pandas as pd

df = pd.read_csv('data.csv')

print(df.head(10))
```

Η έξοδος είναι:

```
>>>
=== RESTART: C:\Users\NK\AppData\Local\Prog
   Duration  Pulse  Maxpulse  Calories
0        60    110       130     409.1
1        60    117       145     479.0
2        60    103       135     340.0
3        45    109       175     282.4
4        45    117       148     406.0
5        60    102       127     300.5
6        60    110       136     374.0
7        45    104       134     253.3
8        30    109       133     195.1
9        60     98       124     269.0
>>>
```

Υπάρχει επίσης η μέθοδος tail()για την προβολή των *τελευταίων* σειρών του DataFrame. Επίσης, επιστρέφει και τις κεφαλίδες και ο αριθμός σειρών, είναιι όπως και παραπάνω συγκεκριμένος.

Παράδειγμα:

```
print(df.tail())
```

```
>>>
=== RESTART: C:\Users\NK\AppData\Local\Prog
     Duration  Pulse  Maxpulse  Calories
164        60    105       140     290.8
165        60    110       145     300.4
166        60    115       145     310.2
167        75    120       150     320.4
168        75    125       150     330.4
>>>
```

24.1.12 Πληροφορίες για τα Δεδομένα

Το αντικείμενο DataFrame έχει μια μέθοδο που ονομάζεται info(), η οποία μας δίνει περισσότερες πληροφορίες σχετικά με το σύνολο των δεδομένων.

Ας πάρουμε μια εκτύπωση της εντολής:

```
print(df.info())
```

```
>>>
=== RESTART: C:\Users\NK\AppData\Local\Pr
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 169 entries, 0 to 168
Data columns (total 4 columns):
 #   Column    Non-Null Count  Dtype
---  ------    --------------  -----
 0   Duration  169 non-null    int64
 1   Pulse     169 non-null    int64
 2   Maxpulse  169 non-null    int64
 3   Calories  164 non-null    float64
dtypes: float64(1), int64(3)
memory usage: 5.4 KB
None
>>>
```

Από την παραπάνω εκτύπωση, μαθαίνουμε ότι στο έγγραφο, υπάρχουν 169 καταχωρήσεις και 4 στήλες δεδομένων.

Η info()μέθοδος μας λέει επίσης πόσες Non-Null τιμές υπάρχουν σε κάθε στήλη και στο σύνολο δεδομένων μας φαίνεται ότι υπάρχουν 164 από 169 Non-Null τιμές στη στήλη "Calories".

Που σημαίνει ότι υπάρχουν 5 σειρές χωρίς καμία απολύτως αξία, στη στήλη «Calories», για κάποιο λόγο.

Οι κενές ή οι μηδενικές τιμές μπορεί να δημιουργήσουν θέμα κατά την ανάλυση δεδομένων και θα πρέπει να εξετάσουμε το ενδεχόμενο κατάργησης των σειρών με κενές τιμές.

Αυτό είναι ένα βήμα προς αυτό που ονομάσαμε προηγουμένως καθαρισμό δεδομένων. Ας δούμε περισσότερα γι’ αυτό

24.1.13 Καθαρισμός δεδομένων – Data Cleaning

Καθαρισμός δεδομένων σημαίνει να διορθώνουμε άχρηστα δεδομένα στο data set μας.

- Άχρηστα ή και επιζήμια δεδομένα μπορεί να είναι:
- Κενά κελιά
- Δεδομένα σε λάθος μορφή

- Λανθασμένα δεδομένα
- Διπλά δεδομένα

Ας δούμε πώς τα διαχειριζόμαστε όλα αυτά. Κατεβάζουμε ένα νέο αρχείο, το data2.csv

Αν ανοίξουμε το αρχείο, θα δούμε ότι

Duration	Date	Pulse	Maxpulse	Calories
0	60 '2020/12/01'	110	130	409.1
1	60 '2020/12/02'	117	145	479.0
2	60 '2020/12/03'	103	135	340.0
3	45 '2020/12/04'	109	175	282.4
4	45 '2020/12/05'	117	148	406.0
5	60 '2020/12/06'	102	127	300.0
6	60 '2020/12/07'	110	136	374.0
7	450 '2020/12/08'	104	134	253.3
8	30 '2020/12/09'	109	133	195.1
9	60 '2020/12/10'	98	124	269.0
10	60 '2020/12/11'	103	147	329.3
11	60 '2020/12/12'	100	120	250.7
12	60 '2020/12/12'	100	120	250.7
13	60 '2020/12/13'	106	128	345.3
14	60 '2020/12/14'	104	132	379.3
15	60 '2020/12/15'	98	123	275.0
16	60 '2020/12/16'	98	120	215.2

17	60	'2020/12/17'	100	120	300.0
18	45	'2020/12/18'	90	112	NaN
19	60	'2020/12/19'	103	123	323.0
20	45	'2020/12/20'	97	125	243.0
21	60	'2020/12/21'	108	131	364.2
22	45	NaN	100	119	282.0
23	60	'2020/12/23'	130	101	300.0
24	45	'2020/12/24'	105	132	246.0
25	60	'2020/12/25'	102	126	334.5
26	60	2020/12/26	100	120	250.0
27	60	'2020/12/27'	92	118	241.0
28	60	'2020/12/28'	103	132	NaN
29	60	'2020/12/29'	100	132	280.0
30	60	'2020/12/30'	102	129	380.3
31	60	'2020/12/31'	92	115	243.0

- Το data set περιέχει μερικά κενά κελιά ("Date" στη σειρά 22 και "Calories" στις σειρές 18 και 28).
- Λάθος μορφή/τύπο δεδομένων ("Date" στη σειρά 26).
- Λάθος δεδομένα ("Duration" στη σειρά 7).
- Διπλότυπα (σειρές 11 και 12).

24.1.14 Καθαρισμός κενών κελιών και απαλοιφή γραμμών

Καθότι όπως είπαμε, τα κενά κελιά μπορεί να μας δώσουν λανθασμένα αποτελέσματα στις αναλύσεις μας, ένας τρόπος να τα αφαιρέσουμε είναι να αφαιρέσουμε τις γραμμές που περιέχουν τα κενά κελιά.

Επειδή συνήθως διαχειριζόμαστε πολλά δεδομένα (big data), η αφαίρεση μερικών γραμμών δεν θα επηρεάσει το αποτέλεσμά μας.

Ας δούμε πως επιστρέφουμε ένα DataFrame χωρίς κενά κελιά

```
import pandas as pd

df = pd.read_csv('data.csv')

new_df = df.dropna()

print(new_df.to_string())
```

ΣΗΜΕΙΩΣΗ: Από προεπιλογή, η μέθοδος dropna() επιστρέφει ένα νέο DataFrame και δεν θα αλλάξει το πρωτότυπο

```
>>>
=== RESTART: C:\Users\NK\AppData\Local\Programs\Python\Python3
          Duration          Date  Pulse  Maxpulse  Calories
0     0        60  '2020/12/01'    110       130     409.1
1     1        60  '2020/12/02'    117       145     479.0
2     2        60  '2020/12/03'    103       135     340.0
3     3        45  '2020/12/04'    109       175     282.4
4     4        45  '2020/12/05'    117       148     406.0
5     5        60  '2020/12/06'    102       127     300.0
6     6        60  '2020/12/07'    110       136     374.0
7     7       450  '2020/12/08'    104       134     253.3
8     8        30  '2020/12/09'    109       133     195.1
9     9        60  '2020/12/10'     98       124     269.0
10    10       60  '2020/12/11'    103       147     329.3
11    11       60  '2020/12/12'    100       120     250.7
12    12       60  '2020/12/12'    100       120     250.7
13    13       60  '2020/12/13'    106       128     345.3
14    14       60  '2020/12/14'    104       132     379.3
15    15       60  '2020/12/15'     98       123     275.0
16    16       60  '2020/12/16'     98       120     215.2
17    17       60  '2020/12/17'    100       120     300.0
18    18       45  '2020/12/18'     90       112       NaN
19    19       60  '2020/12/19'    103       123     323.0
20    20       45  '2020/12/20'     97       125     243.0
21    21       60  '2020/12/21'    108       131     364.2
22    22       45           NaN    100       119     282.0
23    23       60  '2020/12/23'    130       101     300.0
24    24       45  '2020/12/24'    105       132     246.0
25    25       60  '2020/12/25'    102       126     334.5
26    26       60    2020/12/26    100       120     250.0
27    27       60  '2020/12/27'     92       118     241.0
28    28       60  '2020/12/28'    103       132       NaN
29    29       60  '2020/12/29'    100       132     280.0
30    30       60  '2020/12/30'    102       129     380.3
31    31       60  '2020/12/31'     92       115     243.0
>>>
```

Για να αλλάξουμε το αρχικό DataFrame, χρησιμοποιούμε το όρισμα inplace = True:

```
import pandas as pd

df = pd.read_csv('data.csv')

df.dropna(inplace = True)

print(df.to_string())
```

24.1.15 Αντικατάσταση κενών τιμών

Ένας άλλος τρόπος αντιμετώπισης των κενών κελιών είναι να εισάγουμε στη θέση τους μια *νέα* τιμή.

Με αυτόν τον τρόπο δεν χρειάζεται να διαγράψουμε ολόκληρες σειρές μόνο και μόνο λόγω κάποιων κενών κελιών.

Η μέθοδος fillna() μας επιτρέπει να αντικαταστήσουμε τα κενά κελιά με μια τιμή. Στην προκειμένη περίπτωση, αντικαθιστούμε τα κενά κελιά με την τιμή 130

```
>>>
=== RESTART: C:\Users\NK\AppData\Local\Programs\Python\Python31
    Duration          Date  Pulse  Maxpulse  Calories
0      60  '2020/12/01'    110       130     409.1
1      60  '2020/12/02'    117       145     479.0
2      60  '2020/12/03'    103       135     340.0
3      45  '2020/12/04'    109       175     282.4
4      45  '2020/12/05'    117       148     406.0
5      60  '2020/12/06'    102       127     300.0
6      60  '2020/12/07'    110       136     374.0
7     450  '2020/12/08'    104       134     253.3
8      30  '2020/12/09'    109       133     195.1
9      60  '2020/12/10'     98       124     269.0
10     60  '2020/12/11'    103       147     329.3
11     60  '2020/12/12'    100       120     250.7
12     60  '2020/12/12'    100       120     250.7
13     60  '2020/12/13'    106       128     345.3
14     60  '2020/12/14'    104       132     379.3
15     60  '2020/12/15'     98       123     275.0
16     60  '2020/12/16'     98       120     215.2
17     60  '2020/12/17'    100       120     300.0
18     45  '2020/12/18'     90       112       NaN
19     60  '2020/12/19'    103       123     323.0
20     45  '2020/12/20'     97       125     243.0
21     60  '2020/12/21'    108       131     364.2
22     45           NaN    100       119     282.0
23     60  '2020/12/23'    130       101     300.0
24     45  '2020/12/24'    105       132     246.0
25     60  '2020/12/25'    102       126     334.5
26     60    2020/12/26    100       120     250.0
27     60  '2020/12/27'     92       118     241.0
28     60  '2020/12/28'    103       132       NaN
29     60  '2020/12/29'    100       132     280.0
30     60  '2020/12/30'    102       129     380.3
31     60  '2020/12/31'     92       115     243.0
>>>
```

Μπορούμε να αντικαταστήσουμε κενά κελιά, μόνο σε συγκεκριμένες στήλες, καθορίζοντας τις στήλες.

Στο παρακάτω παράδειγμα, αντικαθιστούμε τις κενές τιμές στη στήλη “Calories” με τον αριθμό 130.

```
import pandas as pd

df = pd.read_csv('data.csv')

df["Calories"].fillna(130, inplace = True)
```

Ζητώντας και μια εκτύπωση: print(df)

```
>>>
=== RESTART: C:\Users\NK\AppData\Local\Progr
     Duration  Pulse  Maxpulse  Calories
0          60    110       130     409.1
1          60    117       145     479.0
2          60    103       135     340.0
3          45    109       175     282.4
4          45    117       148     406.0
..        ...    ...       ...       ...
164        60    105       140     290.8
165        60    110       145     300.4
166        60    115       145     310.2
167        75    120       150     320.4
168        75    125       150     330.4

[169 rows x 4 columns]
>>>
```

21.1.16 Αντικατάσταση τιμών, χρησιμοποιώντας τις Mean, Median και Mode

Αποτελεί συνηθισμένο τρόπο η αντικατάσταση κενών κελιών με τον υπολογισμό της μέσης τιμής (mean = μέσος όρος), της διάμεσης τιμής (median = ο μέσος όρος των μοναδικών τιμών) ή της πιο συχνά εμφανιζόμενης τιμής (mode) της στήλης.

Έτσι έχουμε τις μεθόδους mean(), median() και mode() για τον υπολογισμό και την αντικατάσταση των κενών τιμών.

Παράδειγμα 1

Υπολογισμός και αντικατάσταση κενών τιμών με τη mean()

```
import pandas as pd

df = pd.read_csv('data.csv')

x = df["Calories"].mean()

df["Calories"].fillna(x, inplace = True)
print(df)
```

```
>>>
=== RESTART: C:\Users\NK\AppData\Local\Progra
     Duration  Pulse  Maxpulse  Calories
0          60    110       130     409.1
1          60    117       145     479.0
2          60    103       135     340.0
3          45    109       175     282.4
4          45    117       148     406.0
..        ...    ...       ...       ...
164        60    105       140     290.8
165        60    110       145     300.4
166        60    115       145     310.2
167        75    120       150     320.4
168        75    125       150     330.4

[169 rows x 4 columns]
>>>
```

Παράδειγμα 2

Υπολογισμός και αντικατάσταση κενών τιμών με τη median()

```
import pandas as pd

df = pd.read_csv('C:\\Users\\NK\\Desktop\\data.csv')

x = df["Calories"].median()

df["Calories"].fillna(x, inplace = True)

print(df)
```

```
>>>
=== RESTART: C:\Users\NK\AppData\Local\Program
     Duration  Pulse  Maxpulse  Calories
0          60    110       130     409.1
1          60    117       145     479.0
2          60    103       135     340.0
3          45    109       175     282.4
4          45    117       148     406.0
..        ...    ...       ...       ...
164        60    105       140     290.8
165        60    110       145     300.4
166        60    115       145     310.2
167        75    120       150     320.4
168        75    125       150     330.4

[169 rows x 4 columns]
>>>
```

Παράδειγμα 3

Υπολογισμός και αντικατάσταση κενών τιμών με τη mode()

```
import pandas as pd

df = pd.read_csv('data.csv')

x = df["Calories"].mode()[0]

df["Calories"].fillna(x, inplace = True)

print(df)
```

```
>>>
=== RESTART: C:\Users\NK\AppData\Local\Pro
     Duration  Pulse  Maxpulse  Calories
0          60    110       130     409.1
1          60    117       145     479.0
2          60    103       135     340.0
3          45    109       175     282.4
4          45    117       148     406.0
..        ...    ...       ...       ...
164        60    105       140     290.8
165        60    110       145     300.4
166        60    115       145     310.2
167        75    120       150     320.4
168        75    125       150     330.4

[169 rows x 4 columns]
>>>
```

24.1.16 Ασκήσεις

Χρησιμοποιήστε το αρχείο data.csv για να λύσετε τις παρακάτω ασκήσεις.

Άσκηση 1

Αντικαταστήστε τις κενές τιμές με συγκεκριμένη τιμή. Αντικαταστήστε όλες τις κενές τιμές στη στήλη 'Calories' με την τιμή 0.

Άσκηση 2

Αντικαταστήστε τις κενές τιμές σε συγκεκριμένες στήλες

Αντικαταστήστε τις κενές τιμές στις στήλες 'Maxpulse' και'Pulse' με την τιμή mean κάθε στήλης

Άσκηση 3

Αντικεταστήστε τις κενές τιμές με την πιο συχνή τιμή της στήλης (Mode)

Αντικαταστήστε τις κενές τιμές στη στήλη 'Duration' με τη mode (πιο συχνή τιμή) της στήλης.